

Introduction to Data Science

Studi Kasus Dataset: Quebec Housing Sales Dataset (Kaggle)

PA2-W7-S11



KLARIN KINTANY

| NIM : 2902785173

Introduction to Data Science

Binus Online University

2025 Even Semester, Periode 2

Soal 1 : Konsep *Exploratory Data Analysis* (EDA)

1.1 Apa itu EDA dan Mengapa Penting?

Exploratory Data Analysis (EDA) adalah tahapan awal dalam proses analisis data yang bertujuan untuk memahami karakteristik, pola, struktur, dan kualitas suatu dataset sebelum dilakukan pemodelan lebih lanjut. EDA dilakukan dengan menggabungkan ringkasan statistik (statistik deskriptif) dan visualisasi data untuk menemukan pola, hubungan antar variabel, anomaly (outlier), serta menguji asumsi awal terhadap data.

EDA menjadi tahap yang sangat penting dalam Data Science Workflow karena beberapa alasan utama. Pertama, EDA membantu mendeteksi masalah kualitas data secara dini, seperti missing values, duplikasi data, atau kesalahan input, sehingga dapat ditangani sebelum data digunakan untuk pemodelan. Kedua, EDA memberikan pemahaman awal mengenai distribusi dan hubungan antar variabel, yang menjadi dasar dalam menentukan teknik pra proses data (misalnya normalisasi atau transformasi) serta pemilihan algoritma machine learning yang sesuai. Ketiga, EDA membantu mengidentifikasi outlier dan anomali yang dapat mempengaruhi kinerja model secara signifikan jika tidak ditangani dengan tepat. Terakhir, insight yang dihasilkan dari EDA dapat mendukung pengambilan keputusan bisnis secara lebih cepat, bahkan sebelum tahap pemodelan prediktif dilakukan.

1.2 Manfaat Teknik Visualisasi dalam EDA

- **Histogram:** Digunakan untuk melihat distribusi data suatu variabel numerik, termasuk pusat data (central tendency), sebaran (spread), dan bentuk distribusi (simetris, condong kiri/kanan, atau bimodal). Histogram membantu menentukan apakah data mendekati distribusi normal atau memerlukan transformasi sebelum dimodelkan.
- **Boxplot:** Digunakan untuk mendeteksi outlier melalui representasi kuartil (Q1, median, Q3) dan batas whisker yang dihitung menggunakan metode IQR (Interquartile Range). Boxplot juga memudahkan perbandingan sebaran data antar kelompok atau kategori secara berdampingan.
- **Scatter Plot:** Digunakan untuk melihat hubungan (korelasi) antara dua variabel numerik secara visual. Pola titik-titik pada scatter plot dapat menunjukkan hubungan linear positif, negatif, atau tidak ada hubungan sama sekali, serta membantu mengidentifikasi outlier dua dimensi.

- **Heatmap:** Digunakan untuk menganalisis dan memvisualisasikan matriks korelasi antar banyak variabel numerik sekaligus. Dengan skema warna, heatmap memudahkan identifikasi pasangan variabel dengan korelasi kuat (positif maupun negatif) secara cepat tanpa harus membaca tabel angka satu per satu.

1.3 Studi Kasus Nyata Penerapan EDA di Industri

Salah satu contoh penerapan EDA di industri adalah pada sektor e-commerce, khususnya dalam analisis perilaku pelanggan. Perusahaan e-commerce seperti marketplace online biasanya memiliki data transaksi dalam jumlah besar yang mencakup histori pembelian, kategori produk, waktu transaksi, metode pembayaran, dan nilai transaksi.

Melalui EDA, tim data science dapat menampilkan histogram nilai transaksi untuk memahami segmentasi pelanggan (misalnya pelanggan bernilai rendah, menengah, dan tinggi), menggunakan boxplot untuk mendeteksi transaksi yang tidak wajar (berpotensi indikasi fraud), serta menggunakan scatter plot dan heatmap untuk melihat hubungan antara frekuensi kunjungan, durasi sesi, dan kemungkinan checkout.

Hasil EDA ini kemudian menjadi dasar untuk membangun model prediktif seperti churn prediction (memprediksi pelanggan yang berpotensi berhenti berbelanja) atau sistem rekomendasi produk yang lebih personal, sehingga strategi pemasaran dapat dirancang secara lebih tepat sasaran dan berbasis data.

Soal 2: Praktik Eksplorasi Data

2.1 Deskripsi Dataset (Quebec Housing Sales)

- a. Dataset yang digunakan adalah Quebec Housing Sales, yang berisi data transaksi penjualan properti residensial di berbagai kota di provinsi Quebec, Kanada. Dataset ini terdiri dari 5.000 baris data dan 14 kolom (fitur), mencakup informasi seperti kota, tipe properti (Single Family, Condo, Townhouse, Duplex, Triplex, Bungalow), jumlah kamar tidur dan kamar mandi, luas bangunan, luas lahan, tahun dibangun, tahun renovasi, ketersediaan garasi dan basement, tahun penjualan, serta harga jual (target/variabel utama analisis).

<https://www.kaggle.com/datasets/rickyjackson/quebec-housing-sales-price/data>

🔗 IDS_PA2_W7_S11_Klarin Kintany_2902785173.ipynb

```
Ukuran dataset: (5000, 14)
<class 'pandas.DataFrame'>
RangeIndex: 5000 entries, 0 to 4999
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   property_id           5000 non-null   int64
1   city                  5000 non-null   str
2   neighborhood          5000 non-null   str
3   property_type         5000 non-null   str
4   bedrooms              5000 non-null   int64
5   bathrooms             5000 non-null   int64
6   living_area_sqft      5000 non-null   int64
7   lot_size_sqft         3789 non-null   float64
8   year_built            5000 non-null   int64
9   renovation_year       1592 non-null   float64
10  garage                5000 non-null   str
11  basement              5000 non-null   str
12  sale_year             5000 non-null   int64
13  sale_price            5000 non-null   int64
dtypes: float64(2), int64(7), str(5)
memory usage: 547.0 KB
```

b. Menampilkan 5 baris pertama Dataset

	property_id	city	neighborhood	property_type	bedrooms	bathrooms	living_area_sqft	lot_size_sqft	year_built
0	1	Châteauguay	Centre-Ville	Townhouse	3	2	1160	2304.0	2022
1	2	Trois-Rivières	Cap-de-la-Madeleine	Duplex	4	4	1807	5869.0	2006
2	3	Lévis	Charny	Townhouse	3	1	803	3387.0	1989
3	4	Laval	Fabreville	Single Family	3	3	1083	11417.0	1972
4	5	Longueuil	Greenfield Park	Condo	2	2	714	NaN	1997

2.2 Ringkasan Missing Values

Hasil pemeriksaan menunjukkan dua kolom memiliki missing values: `lot_size_sqft` (1.211 baris kosong, 24,22%) dan `renovation_year` (3.408 baris kosong, 68,16%). Nilai kosong pada `renovation_year` secara logis menunjukkan properti yang belum pernah direnovasi, sehingga bukan merupakan data hilang secara acak, melainkan kategori "tidak berlaku" (not applicable).

	missing_count	missing_pct(%)
<code>lot_size_sqft</code>	1211	24.22
<code>renovation_year</code>	3408	68.16


2.3 Statistik Deskriptif

	Mean	Median	Std Dev	Skewness	Kurtosis
bedrooms	3.488200	3.0	1.357435	0.443272	-0.154855
bathrooms	2.325800	2.0	0.968009	0.667978	0.659093
living_area_sqft	1313.693800	1273.0	472.106052	0.450176	-0.285009
lot_size_sqft	6257.154658	5767.0	2811.434500	0.683406	-0.194550
year_built	1983.074000	1985.0	26.483028	-0.707988	0.366143
sale_price	480214.000000	453000.0	177125.385206	0.978991	1.635350

Variabel `sale_price` menunjukkan skewness positif (0,98), mengindikasikan distribusi condong ke kanan akibat sejumlah kecil properti bernilai sangat tinggi. Nilai kurtosis (1,64) yang lebih besar dari 0 menunjukkan distribusi lebih runcing (leptokurtic) dibanding distribusi normal, mengonfirmasi adanya outlier harga tinggi.


2.4 Visualisasi Data

a. Histogram (Distribusi Harga Jual)




Histogram menunjukkan mayoritas rumah terjual pada kisaran CAD 350.000–550.000. Distribusi condong ke kanan (right-skewed), terlihat dari posisi mean (CAD 480.214) yang berada di atas median (CAD 453.000), mengindikasikan adanya sejumlah properti bernilai tinggi yang menarik rata-rata ke atas.

b. Boxplot Deteksi Outlier Harga Jual per Tipe Properti




Boxplot menunjukkan median harga jual berbeda antar tipe properti, dengan Single Family dan Duplex cenderung memiliki median lebih tinggi dibanding Condo. Berdasarkan metode IQR, ditemukan sekitar 89 baris (1,78%) data sale_price yang berada di luar batas wajar (di atas $\pm$ CAD 930.875), merepresentasikan segmen rumah premium/mewah.

c. Scatter Plot Hubungan Luas Bangunan dan Harga Jual



Scatter plot memperlihatkan hubungan positif antara `living_area_sqft` dan `sale_price` dengan korelasi Pearson sebesar 0,63. Artinya, semakin luas bangunan suatu properti, semakin tinggi kecenderungan harga jualnya. Namun sebaran titik data yang cukup lebar pada luas bangunan yang sama menunjukkan bahwa faktor lain seperti lokasi, tipe properti, dan kondisi renovasi turut mempengaruhi harga secara signifikan.

d. Heatmap Korelasi Antar Fitur Numerik



Heatmap mengonfirmasi bahwa `living_area_sqft` merupakan prediktor numerik terkuat terhadap `sale_price` ($r = 0,63$), diikuti oleh `bedrooms` ($r = 0,47$) dan `bathrooms` ($r = 0,46$). Sebaliknya, `year_built` dan `lot_size_sqft` memiliki korelasi yang jauh lebih lemah terhadap harga jual. Terlihat pula korelasi tinggi antar fitur ukuran (`bedrooms`, `bathrooms`, `living_area_sqft`), yang mengindikasikan potensi multikolinearitas apabila fitur-fitur ini digunakan bersamaan dalam model regresi.

2.5 Interpretasi Hasil Eksplorasi

Secara keseluruhan, hasil eksplorasi data menunjukkan bahwa harga jual rumah di Quebec sangat dipengaruhi oleh ukuran fisik properti, terutama luas bangunan. Terdapat pola konsisten di mana tipe properti yang lebih besar (Single Family, Duplex) memiliki harga jual median yang lebih tinggi dibanding tipe properti yang lebih kecil seperti Condo. Distribusi harga jual yang condong ke kanan serta adanya outlier pada segmen harga tinggi menunjukkan keberadaan pasar rumah premium yang terpisah dari pasar rumah pada umumnya. Hubungan antar fitur ukuran (kamar tidur, kamar mandi, luas bangunan) yang saling berkorelasi tinggi juga perlu diperhatikan pada tahap pemodelan lanjutan agar tidak menimbulkan masalah multikolinearitas.

2.6 Tantangan yang Dihadapi dan Cara Mengatasinya

- **Missing values pada renovation_year:** Sebagian besar nilai kosong sebenarnya bermakna "belum pernah direnovasi", bukan data yang benar-benar hilang. Hal ini diatasi dengan tidak menghapus baris tersebut, melainkan mempertimbangkan pembuatan kolom biner tambahan (misalnya `is_renovated`) pada tahap analisis lanjutan.
- **Distribusi sale_price yang skewed:** Skewness positif pada harga jual dapat mempengaruhi akurasi model prediktif berbasis asumsi normalitas. Hal ini dapat diatasi dengan transformasi logaritmik (`log-transform`) pada tahap pemodelan.
- **Multikolinearitas antar fitur ukuran:** Korelasi tinggi antara bedrooms, bathrooms, dan `living_area_sqft` berpotensi menimbulkan redundansi informasi. Hal ini dapat ditangani dengan teknik reduksi dimensi (misalnya PCA) atau seleksi fitur pada tahap pemodelan.
- **Data kategorikal beragam (32 kota, 6 tipe properti):** Jumlah kategori kota yang banyak memerlukan teknik encoding yang tepat (misalnya target encoding) agar tidak menghasilkan terlalu banyak fitur dummy saat proses pemodelan machine learning.

REFERENSI

Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: With Applications in R* (2nd ed.). Springer.
<https://doi.org/10.1007/978-1-0716-1418-1>

McKinney, W. (2022). *Python for Data Analysis* (3rd ed.). O'Reilly Media.

Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

Kaggle. (2024). *Quebec Housing Sales Dataset*. [Quebec Housing Sales price](#)

Pandas Development Team. (2024). *pandas documentation*. <https://pandas.pydata.org/docs/>

Matplotlib Development Team. (2024). *Matplotlib: Visualization with Python*.
<https://matplotlib.org/>

Seaborn Development Team. (2024). *Seaborn Statistical Data Visualization*.
<https://seaborn.pydata.org/>

NumPy Developers. (2024). *NumPy User Guide*. <https://numpy.org/doc/>

Cleveland, W. S. (1993). *Visualizing Data*. Hobart Press.

Wickham, H. (2014). Tidy Data. *Journal of Statistical Software*, 59(10), 1–23.
<https://doi.org/10.18637/jss.v059.i10>